

DÉTECTION DE CONTREFAÇON DES BILLETS

par Machine Learning

Présentée par : Raïssa BURGUERA

Objectifs de la Mission

Pourquoi ce projet ?



Lutter contre la contrefaçon

La falsification des billets représente un risque majeur pour l'économie.



Développer un outil automatique

Concevoir un algorithme capable de décider si un billet est authentique ou contrefait à partir de ses seules mesures géométriques.

Vue d'ensemble du projet

1



Analyse
exploratoire

2



Imputation
valeurs
manquantes

3



Modélisation
supervisée

Rég. Log.
KNN
Random Forest

4



Modélisation
non-supervisée

K-Means

5



Choix du
meilleur modèle

Accuracy
Précision
Recall
ROC-AUC

6



Fonction de
prédiction

Nouveaux
Billets;
Verdict +
Probabilité

I. Analyse Exploratoire des Données

1 Analyse exploratoire

2 Imputation valeurs manquantes

3 Modélisation supervisée


4 Modélisation non-supervisée

5 Choix du meilleur modèle

6 Fonction de prédiction

Présentation du jeu de données

Billet de 100 € — Dimensions caractéristiques



--- Diagonal

Ligne pointillée coin à coin



Length

Largeur totale du billet



Height_left

Hauteur côté gauche



Height_right

Hauteur côté droit



Margin_up / Margin_low

Marges haut et bas (zone imprimée)

1 500

Billets analysés

1 000

Authentiques (66,7%)

500

Contrefaits (33,3%)

6

Dimensions mesurées

I. Analyse Exploratoire des Données

1	Analyse exploratoire	2	Imputation valeurs manquantes	3	Modélisation supervisée	4	Modélisation non-supervisée	5	Choix du meilleur modèle	6	Fonction de prédiction
---	----------------------	---	-------------------------------	---	-------------------------	---	-----------------------------	---	--------------------------	---	------------------------

Répartition & moyennes par catégorie

Moyennes des 6 dimensions selon la nature du billet (authentique vs contrefaçon)

is_genuine	diagonal	height_left	height_right	margin_low	margin_up	length
False (Faux)	171.901	104.190	104.144	5.216	3.350	111.631
True (Vrai)	171.987	103.949	103.809	4.116	3.052	113.202

Écarts faux – vrais billets :

margin_low

+1.10 mm — Mauvais centrage d'impression

length

+1.57 mm — Variable la plus discriminante

I. Analyse Exploratoire des Données

1 Analyse exploratoire

2 Imputation valeurs manquantes

3 Modélisation supervisée


4 Modélisation non-supervisée

5 Choix du meilleur modèle

6 Fonction de prédiction

Heatmap de corrélation

Heatmap de corrélation des variables



Corrélation

+0.85

length ↔ is_genuine

Plus le billet est long, plus il est probablement vrai.

Corrélation

-0.78

margin_low ↔ is_genuine

Grande marge basse = signal fort de contrefaçon.

I. Analyse Exploratoire des Données

1 Analyse exploratoire

2 Imputation valeurs manquantes


3 Modélisation supervisée

4 Modélisation non-supervisée

5 Choix du meilleur modèle

6 Fonction de prédiction

Scatterplot — Répartition des dimensions



Ce qu'on observe :

Length & Margin_low

Deux nuages de points nettement séparés

II. Imputation des valeurs manquantes

1 Analyse exploratoire

2 Imputation val. manquantes


3 Modélisation supervisée

4 Modélisation non-supervisée

5 Choix du meilleur modèle

6 Fonction de prédiction

Nettoyage — Valeurs manquantes — Imputation par la médiane




Avant imputation

37 valeurs manquantes

Colonne margin_low uniquement — 2,47% du dataset.

Pourquoi la médiane ?

Préserve la distribution réelle des données.



Après imputation

Résultat validé

Distribution préservée après imputation — aucune distorsion introduite.

III. Modélisation — Apprentissage Supervisé

Préparation des données

1

Analyse
exploratoire

2

Imputation
val.
manquantes

3

Modélisation
supervisée

4

Modélisation
non-supervisée

5

Choix du
meilleur modèle

6

Fonction de
prédiction

Comment les données ont été préparées ?

1 500 billets mesurés — Dataset complet



80% — ENTRAÎNEMENT

1 200 billets

Le modèle apprend les caractéristiques des vrais et faux billets sur ces données.

20% — TEST

300
billets

Jamais vus
pendant
l'apprentissage



Proportion maintenue dans les deux ensembles : 2 vrais pour 1 faux

III. Modélisation — Apprentissage Supervisé

A. Régression Logistique — Principe & Résultats

1

Analyse exploratoire

2

Imputation val. manquantes

3

Modélisation supervisée

4

Modélisation non-supervisée

5

Choix du meilleur modèle

6

Fonction de prédiction

Comment fonctionne la regression logistique ?



Classification binaire


Prédit si un billet est VRAI ou FAUX — deux catégories distinctes.



Calcul de probabilité (seuil fixé à 0,5)

Pour chaque billet, le modèle calcule une probabilité entre 0 et 1.
Au-dessus de 0,5 → VRAI, sinon → FAUX.

Résultats sur 300 billets :



Scores de performance

0.99

Accuracy

0.99

Precision

0.99

Recall

0.99

F1-Score

III. Modélisation — Apprentissage Supervisé

B. KNN — (K-Nearest Neighbors)

1

Analyse exploratoire

2

Imputation val. manquantes

3

Modélisation supervisée

4

Modélisation non-supervisée

5

Choix du meilleur modèle

6

Fonction de prédiction

Comment fonctionne le KNN?



Algorithme géométrique


Pour classer un nouveau billet, le modèle regarde ses 10 voisins les plus proches dans l'espace des dimensions.



Vote majoritaire (n=10)

Si la majorité des 10 voisins sont de vrais billets, le nouveau est classé VRAI. Sinon, FAUX.

Résultats sur 300 billets :



Scores de performance

0.99

Accuracy

0.99

Precision

0.99

Recall

0.99

F1-Score

III. Modélisation — Apprentissage Supervisé

C. Random Forest

1

Analyse exploratoire

2

Imputation val. manquantes

3

Modélisation supervisée

4

Modélisation non-supervisée

5

Choix du meilleur modèle

6

Fonction de prédiction

Comment fonctionne le Random Forest ?



100 arbres de décision


On entraîne 100 arbres différents, chacun sur un sous-ensemble aléatoire des données et des variables.



Vote de la majorité

Chaque arbre prédit VRAI ou FAUX. La classe obtenant le plus de votes gagne.

Résultats sur 300 billets :



Scores de performance

0.99

Accuracy

0.99

Precision

0.99

Recall

0.99

F1-Score

IV. Modélisation — Apprentissage non-Supervisé

1

Analyse exploratoire

2

Imputation val. manquantes

3

Modélisation supervisée

4

Modélisation non-supervisée

5

Choix du meilleur modèle

6

Fonction de prédiction

D. K-Means Clustering — Évaluation sur les 20% test

Qu'est-ce que le K-Means ?



Aucune étiquette utilisée

Le modèle ne sait pas à l'avance si un billet est vrai ou faux. Il groupe les données seul.



2 clusters automatiques

L'algorithme crée 2 groupes. On observe ensuite que l'un correspond aux vrais billets, l'autre aux faux.




Réassignation des labels

Puis, on compare les clusters aux vraies étiquettes.

Scores de performance

Résultats sur 300 billets :

**0.99**

Accuracy

0.99

Precision

0.99

Recall

0.99

F1-Score

IV. Modélisation — Apprentissage non-Supervisé

1

Analyse exploratoire

2

Imputation val. manquantes

3

Modélisation supervisée

4

Modélisation non-supervisée


5

Choix du meilleur modèle

6

Fonction de prédiction

D. K-Means Clustering — Visualisation de la séparation des clusters



Interprétation :

Cluster Faux billets (bleu clair)

Billets regroupés vers les petites valeurs de length et grandes valeurs de margin_low.

Cluster Vrais billets (bleu foncé)

Billets bien distincts — length plus élevée, margin_low plus faible.

Séparation nette

Les deux groupes sont visuellement distincts, sans aucun label fourni à l'algorithme.

IV. Modélisation — Apprentissage non-Supervisé

1

Analyse exploratoire

2

Imputation val.
manquantes

3

Modélisation supervisée

4

Modélisation non-supervisée

5


Choix du meilleur modèle

6

Fonction de prédiction

D. K-Means Clustering — Entraînement sur toutes les données

Résultats sur 1500 billets :



Scores de performance:

0.98

Accuracy

0.99

Precision

0.99

Recall

0.99

F1-Score

V. Modélisation — Choix du meilleur modèle

1

Analyse exploratoire

2

Imputation val.
manquantes

3

Modélisation supervisée

4

Modélisation non-supervisée


5

Choix du meilleur modèle

6

Fonction de prédiction

Comparaison des performances — Accuracy & ROC-AUC



Modèle	Accuracy	ROC-AUC
Rég. Logistique	99.0%	0.999
KNN	99.0%	0.997
Random Forest	98.7%	0.999
K-Means	99.0%	—



Modèle retenu

La Régression Logistique : simple, interprétable, AUC parfait et mise en production aisée.

VI. Modélisation — Fonction de prédiction

Fonction de détection — Ce qu'elle fait — Résultats

1	Analyse exploratoire	2	Imputation val. manquantes	3	Modélisation supervisée	4	Modélisation non-supervisée	5	Choix du meilleur modèle	6	Fonction de prédiction
---	----------------------	---	----------------------------	---	-------------------------	---	-----------------------------	---	--------------------------	---	------------------------

Ce que fait la fonction, étape par étape :

- 1

Chargement du fichier
On fournit un fichier CSV contenant les mesures de nouveaux billets à analyser.
- 2

Sélection des variables
On sélectionne les 6 dimensions géométriques utilisées pendant l'entraînement.
- 3

Standardisation
On applique la même mise à l'échelle que pendant l'entraînement — sans recalculer.
- 4

Prédiction + probabilité
Le modèle prédit VRAI ou FAUX et donne une probabilité entre 0% et 100%.
- 5

Retour du résultat
La fonction retourne : l'identifiant du billet, le verdict, et la probabilité.

Exemple de résultats :

ID	Verdict	Probabilité_Vrai
A_1	FAUX BILLET	0.09%
A_2	FAUX BILLET	0.02%
A_3	FAUX BILLET	0.03%
A_4	VRAI BILLET	97.94%
A_5	VRAI BILLET	99.98%

Bilan de la mission



Variables clés identifiées

length (+1,57mm) et margin_low (+1,1mm) sont les deux meilleurs indicateurs de contrefaçon.



Précision remarquable

4 modèles testés, tous à 99% d'accuracy — résultats robustes et cohérents entre eux.



Supervisé et non-supervisé

Rég. Logistique, KNN, Random Forest et K-Means convergent vers les mêmes conclusions.



Mise en production opérationnelle

Fonction prête à l'emploi, retourne verdict + probabilité pour tout nouveau fichier CSV.



Des questions ?

Raïssa BURGUERA — Détection des contrefaçons par Machine Learning